

Informe TFG

Andrés García Treviño

Abril 2026

1 Revisión del código original

1.1 Capas de la red neuronal

La red neuronal inicial era una red LSTM de 1 capa de 24 neuronas y una capa final de 3 neuronas completamente conectadas (Dense).

Para permitir la compatibilidad con otras capas de neuronas y otros entornos de ejecución como Google Colab o Kaggle, he añadido una primera capa de entrada (Input) para establecer el tamaño de los batches (batch_input_size).

```
1  # CNN-LSTM MODEL
2  myCNNLSTM = Sequential()
3  myCNNLSTM.add(Input(batch_shape=(batch_size, look_back, 7, 7,
4  1)))
5  myCNNLSTM.add(TimeDistributed(Conv2D(filters=current_filters,
6  kernel_size=(3,3), padding='same', activation='relu'))))
7  myCNNLSTM.add(TimeDistributed(Flatten())) # Flatten to connect
8  CNN to LSTM
9  myCNNLSTM.add(LSTM(look_back, stateful=True))
10 myCNNLSTM.add(Dense(num_features))
11 myCNNLSTM.compile(loss='mean_squared_error', optimizer='adam')
```

Listing 1: Capa Input en la red CNN+LSTM

1.2 Data leakage por normalización

En el modelo original se utilizan todas las muestras del dataset para generar el objeto `sklearn.preprocessing.MinMaxScaler` con el que se realiza la normalización de los datos. Esto constituye en sí mismo *data leakage*.

El objetivo del paper SKIMA y de el presente TFG es comparar el entrenamiento incremental *online learning* con el entrenamiento estático. Si la red se entrena primeramente pasando 400 veces (n_epochs) por el subset de entrenamiento (train), el subset de test no puede estar incluido en la generación del objeto `sklearn.preprocessing.MinMaxScaler` puesto que la red neuronal estaría preparada de antemano para dicho subset de test y daría unos resultados mejores de los reales.

Además, el entrenamiento de la red neuronal está pensado para desplegar dicha red en un entorno real. En dicho escenario, los datos nuevos que tenga

que procesar la red neuronal no podrían generar el objeto `MinMaxScaler`. Si pudieran, aun así habría que reentrenar la red neuronal cada vez que llegara un nuevo dato.

Lo mismo ocurre con el entrenamiento incremental. Está pensado para que, al desplegar la red neuronal en un entorno real, ésta vaya adaptándose a los cambios en los patrones de tráfico, evitando así caer en el *concept drift* y tener que reentrenar la red neuronal. Los nuevos datos que la red tenga que procesar en dicho escenario no van a generar el objeto `MinMaxScaler`, por lo tanto, los datos de test tampoco.

Así, he cambiado el script de python de esta forma:

```
1 # BATCH NORMALIZATION
2 scaler = MinMaxScaler(feature_range=(0, 1))
3
4 # se escala con los datos de test. DATA LEAKAGE
5 dataset = scaler.fit_transform(dataset)
6 dataset = dataset[0:1475]
7 # SEPARATE INTO TRAIN AND TEST
8
9 train_size = 400#int(len(dataset) * 0.7)
10 test_size = 1075#len(dataset) - train_size
11 train, test = dataset[0:train_size, :], dataset[train_size:
    train_size+test_size, :]
12 print(len(train), len(test))
```

Listing 2: Escalado del dataset sin data leakage

1.3 Data leakage por falta de validación

Puede parecer que el sistema de entrenamiento y búsqueda de los hiperparámetros más convenientes para la red neuronal está falto de un set de validación y es cierto. Sin embargo, cuento con que sea posible obtener más datos para generar un subset de test adicional. Por ello, aunque en todos los scripts aparezca el subset de validación nombrado como *test*, sigue siendo validación. Al encontrar la mejor combinación de hiperparámetros, probaré con nuevos datos para comprobar que es una red neuronal viable y no una demasiado adaptada a los datos de validación.

1.4 Reproducibilidad

Con 3 celdas fijar la semilla de Tensorflow es suficiente. Al aumentar a 49 celdas ya no lo es, los procesadores como la GPU utilizan algoritmos de eficiencia en el que reparten la computación por los diferentes hilos y núcleos. Para que mi ordenador personal arrojara resultados reproducibles fijé más semillas y forcé a la GPU a ser determinista.

```
1 # fix random seed for reproducibility
2 os.environ['PYTHONHASHSEED'] = '0'
3 os.environ['TF_DETERMINISTIC_OPS'] = '1'
4 os.environ['TF_CUDNN_DETERMINISTIC'] = '1'
5 os.environ['TF_ENABLE_ONEDNN_OPTS'] = '0'
```

```

6 random.seed(7)
7 np.random.seed(7)
8 tf.random.set_seed(7)

```

Listing 3: Código para la reproducibilidad

1.5 Optimización del código

1.5.1 Cálculo dinámico del tamaño de los datasets

Como la red neuronal es stateful, es decir, se guardan los estados internos de la LSTM de una a otra, el tamaño de los datasets ha de ser divisible entre el tamaño de los batches, puesto que keras y tensorflow no permiten que una red LSTM stateful procese un batch incompleto. Por ello, he calculado dinámicamente los tamaños del set de entrenamiento y de test. El set de entrenamiento se ajusta a ser lo más cercano a 400 muestras, como estaba en el código original. El set de test utiliza el resto, siempre siendo divisible por el tamaño del batch.

```

1 # SEPARATE INTO TRAIN AND TEST
2 desired_train_size = 400
3 train_available_batches = (desired_train_size -
4   current_look_back - 1) // current_batch_size
5 train_size = current_batch_size * train_available_batches +
6   current_look_back + 1
7 #create_dataset se come las primeras look_back + 1 muestras
8   para crear el dataset de test/train
9 available_batches = (total_rows - current_look_back -1 -
10  train_size) // current_batch_size
11 test_size = current_batch_size * available_batches +
12   current_look_back +1
13
14 dataset = dataset_full[0:train_size+test_size]
15 train = dataset[0:train_size, :]
16 test = dataset[train_size : train_size+test_size, :]

```

Listing 4: Adquisición dinámica de datos

1.5.2 Visualización de resultados

Como en una red neuronal que procesa 49 celdas es completamente inviable analizar 49 gráficos como se hacía en la red de 3 celdas original, he decidido crear un plot que me indica el RNMSE en cada celda, tanto de entrenamiento, test estático y entrenamiento incremental. Obviamente, esto solo lo implemento cuando pruebo una única combinación de parámetros. También se guardan los resultados numéricos en un fichero excel.

```

1 # Crear un DataFrame con los resultados
2 region_names = dataframe.columns.tolist()
3 results = {
4     'Region' : region_names,
5     'Train Score': trainScore,
6     'Test Score': testScore,
7     'Test Score incremental': testScore_inc,

```

```

8     'Time Score': [timeScore] * num_features # Repetir el valor de
        timeScore para todas las filas
9 }
10
11 df = pd.DataFrame(results)
12
13 combined_predictions = np.hstack((test_Y_u[batch_size-1:-1,:],
        test_Yhat_su[batch_size-1:-1, :], test_Yhat_ou))
14
15 all_cols = [f'Real_{name}' for name in region_names] + \
16            [f'PredStatic_{name}' for name in region_names] + \
17            [f'PredInc_{name}' for name in region_names]
18
19 df2 = pd.DataFrame(combined_predictions, columns=all_cols)
20
21 filename = f'resultados_norandom3_7x7LSTM_LB{look_back}_BS{
        batch_size}_EU{n_epochs_update}_T{error_threshold}_GWOL'
22 filenameexcel = f'{filename}.xlsx'
23 filenameplot = f'plot{filename}'
24
25 with pd.ExcelWriter(filenameexcel) as writer:
26     df.to_excel(writer, sheet_name='Summary', index=False)
27     df2.to_excel(writer, sheet_name='AllPredictions', index=False)
28
29
30
31 plt.figure(figsize=(15,6))
32
33 plt.plot(np.arange(num_features), trainScore, label='Train', marker
        ='o', color='orange')
34 plt.plot(np.arange(num_features), testScore, label='StaticTest',
        marker='s', color='green')
35 plt.plot(np.arange(num_features), testScore_inc, label='OnlineTest'
        , marker='^', color='firebrick')
36
37 plt.xticks(np.arange(num_features), region_names, rotation=90)
38 plt.tight_layout()
39
40 plt.xlabel('Region')
41 plt.ylabel('RNMSE')
42 plt.title(f'LSTM 7x7 {n_epochs} epochs {n_epochs_update} epoch
        update')
43 plt.legend(loc='best')
44
45 plt.savefig(filenameplot, dpi=300)
46
47 plt.show()

```

Listing 5: Nuevo método de visualización de resultados

2 Simulaciones

He estado realizando bastantes simulaciones con mi propio ordenador, aprovechando que tiene GPU, para intentar entrenar la redes neuronales. Sin embargo, aunque para una o dos veces esté bien, mi ordenador ha de estar exclusivamente ded-

cado a ello, cosa que no es posible en muchos casos porque tengo que utilizarlo para otras cosas.

Por ello he probado diferentes plataformas como Google Colab. Ésta es horrible en todos sus sentidos. Sin pagar una millonada apenas te deja hacer nada. Google Colab indicaba que un único entrenamiento de la red 7x7 LSTM tardaba 82 horas. Ni siquiera se podía cerrar la pestaña puesto que el entrenamiento se cortaba y había que volver a empezar.

La última plataforma que he probado es Kaggle, con la que estoy medio contento. Tengo 30 horas gratis de GPU-P-100 a la semana y funciona muy bien. Sin embargo, como ya he comentado, la reproducibilidad es un problema aun habiendo incrementado las medidas para ello.

2.1 Bucle Grid Search

Para evitar ir probando uno a uno los valores de los distintos hiperparámetros que he probado, he creado un bucle que los prueba todos usando la herramienta `itertools`. Comienza definiendo los valores a probar:

```
1 # Parameter tweak for Grid Search
2 hyperparameters = {
3     'look_back': [24],
4     'batch_size': [25],
5     'n_epochs_update': [5, 6, 7],
6     'threshold': [0, 0.05, 0.1],
7     'num_filters': [16, 18, 20]
8 }
9
10 combinations = list(itertools.product(*hyperparameters.values()))
11 output_csv_file = '/kaggle/working/
    GridSearch_CNNLSTM_Intermediate_v2.csv'
```

Listing 6: Hiperparámetros con `itertools`

Después engloba todo el código, tanto de test estático como de entrenamiento incremental, en un bucle que itera las diferentes combinaciones (La parte del código que no he modificado o que es de menor importancia no la he incluido para no hacer el informe excesivamente largo).

```
1 for combi in combinations:
2     tf.keras.backend.clear_session()
3     tf.random.set_seed(7)
4
5     params = dict(zip(hyperparameters.keys(), combi))
6
7     current_look_back = params['look_back']
8     current_batch_size = params['batch_size']
9     current_n_epochs_update = params['n_epochs_update']
10    current_threshold = params['threshold']
11    current_filters = params['num_filters']
12
13    #GENERAR DATASETS
14
15    # GENERAR MODELO
16    myCNNLSTM = Sequential()
```

```

17 myCNNLSTM.add(Input(batch_shape=(batch_size, look_back, 7, 7,
18 1)))
19 myCNNLSTM.add(TimeDistributed(Conv2D(filters=current_filters,
20 kernel_size=(3,3), padding='same', activation='relu'))))
21 myCNNLSTM.add(TimeDistributed(Flatten())) # Flatten to connect
22 CNN to LSTM
23 myCNNLSTM.add(LSTM(look_back, stateful=True))
24 myCNNLSTM.add(Dense(num_features))
25 myCNNLSTM.compile(loss='mean_squared_error', optimizer='adam')
26
27 # TRAIN MODEL
28 print('Fitting myCNNLSTM on verbose 0')
29 for i in range(n_epochs):
30     myCNNLSTM.fit(trainX, trainY, epochs=1, batch_size=
31     batch_size, verbose=0, shuffle=True)
32     # Keras 3 Safe Reset
33     for layer in myCNNLSTM.layers:
34         if hasattr(layer, 'reset_states'):
35             layer.reset_states()
36
37 # STATIC TEST
38 train_Y_u = scaler.inverse_transform(trainY)
39 test_Y_u = scaler.inverse_transform(testY)
40
41 train_Yhat_s = myCNNLSTM.predict(trainX, batch_size=batch_size)
42 train_Yhat_su = scaler.inverse_transform(train_Yhat_s)
43
44 test_Yhat_s = myCNNLSTM.predict(testX, batch_size=batch_size)
45 test_Yhat_su = scaler.inverse_transform(test_Yhat_s)
46
47 # ONLINE LEARNING TEST
48 n_epochs_update = current_n_epochs_update
49 error_threshold = current_threshold
50 rmse_norm = 1
51 online_yhat_u = list()
52 times = list()
53 optimizer = tf.keras.optimizers.Adam()
54
55 # Initialize the LSTM with the last train batch (chronological)
56 online_X = trainX[-batch_size:]
57 online_Y = trainY[-batch_size:]
58
59 print('Applying SKIMA backpropagation')
60
61 # BUCLE DE ENTRENAMIENTO INCREMENTAL
62
63 test_Yhat_ou=np.array(online_yhat_u)
64 times=np.array(times)
65
66 #C LCULO DEL RNMSE
67
68 timeScore = np.mean(times)
69 avg_train_score = np.mean(trainScore)
70 avg_test_score = np.mean(testScore)
71 avg_test_score_inc = np.mean(testScore_inc)
72
73 current_result = {

```

```

70     # GUARDAR RESULTADOS
71 }
72
73 combi_df = pd.DataFrame([current_result])
74 file_exists = os.path.isfile(output_csv_file)
75 combi_df.to_csv(output_csv_file, mode='a', header=not
file_exists, index=False)

```

Listing 7: Bucle Grid Search

2.2 LSTM 3 celdas

Tomando el código original que utilizaba una red LSTM para analizar 3 celdas separadas y suponiendo que los hiperparámetros eran los ideales para esa red y esas celdas, probé a aumentar el número de capas de la red.

También intenté cambiar las funciones de activación pero ello suponía que el GPU no usara los kernel cuDNN y la velocidad de entrenamiento caía muchísimo hasta el punto de tardar varias horas en ejecutar el script una sola vez. Lo descarté de inmediato.

Como los resultados no eran muy reproducibles, decidí que, como no estaba haciendo un Grid Search, entrenar varias veces con el mismo número de capas (super_epochs) y observar la evolución del error. Así, averigüé que, alrededor de 15 o 20 super_epochs podía tener suficientes datos para hacer la media del error.

Los resultados fueron fatídicos. Aumentar el número de capas sólo aumentaba el error RNMSE tanto de entrenamiento (train), test estático (test) y entrenamiento incremental (test_inc). Lo mejor era una sola capa de LSTM.

He hecho unos gráficos en Excel para ilustrarlo mejor. Sin embargo, he sido completamente incapaz de cambiar el nombre de los elementos de la leyenda que aparece a la derecha de cada gráfico. Es sencillo identificarlo puesto que la serie2 es 1 capa, la serie3 es 2 capas, etc...




Figure 1: RNMSE de entrenamiento 3 celdas




Figure 2: RNMSE de test estático 3 celdas




Figure 3: RNMSE de entrenamiento incremental 3 celdas

2.3 7x7 LSTM

El TFG está basado en el uso de una red convolucional (CNN) en una zona de 49 celdas de tráfico dispuestas en un cuadrado de 7x7 celdas contiguas. Por ello he decidido no pasar mucho tiempo entrenando una red neuronal de 3 celdas separadas entre sí.

Primeramente he entrenado una red neuronal compuesta solamente por una capa de LSTM, incluyendo claramente una capa de entrada (Input) y una de salida (Dense).

```
1 myLSTM = Sequential()
2 myLSTM.add(Input(batch_shape=(batch_size, trainX.shape[1],
3                               trainX.shape[2])))
4 myLSTM.add(LSTM(look_back, stateful=True))
5 myLSTM.add(Dense(trainX.shape[2]))
6 myLSTM.compile(loss='mean_squared_error', optimizer='adam')
7 myLSTM.summary()
```

Listing 8: Capas de la red 7x7LSTM

2.3.1 Resultados

Por ahora, sin haber conseguido reproducibilidad, he ejecutado el Grid Search 3 veces. Cuando los ejecuté pensé que sería reproducible, por lo que en la

segunda y tercera ejecución usé los hiperparámetros que mejor lo hicieron en las anteriores ejecuciones. Para evaluarlas, calculé la media del RNMSE de cada celda en cada combinación de hiperparámetros y comparé el error en el entrenamiento incremental, que es el que interesa para el TFG.

La primera ejecución busqué afinar el tamaño de la ventana lookback y el tamaño del batch, siendo los mejores valores lookback=12 y 24 horas y batch-size=25. También descarté actualizar los pesos sólo 3 veces con cada nuevo dato (n_epoch_updates) y usar un threshold mayor al 20%.

En la segunda ví que la ventana lookback se podía reducir a 16 y 20 horas, actualizar los pesos entre 6 y 7 veces con cada nuevo dato y usar un threshold entre 12 y 14%.

En la tercera probé a afinar el tamaño del batch, consiguiendo el óptimo entre 22 y 23 ventanas.

Con dichos resultados, como varias combinaciones de parámetros estaban repetidas entre una y otra ejecución, pude comprobar que no eran resultados reproducibles. La diferencia de resultados era de incluso el 10% de RNMSE, lo que es absolutamente inaceptable.

2.4 7x7 CNN-LSTM

Después he añadido una capa de CNN para extraer la correlación espacial entre las celdas y así la capa LSTM tenga más información para realizar sus predicciones.

Para conectar la red CNN con la red LSTM he introducido una capa de tipo Flatten, que cambia el formato de la salida de la CNN para adaptarlo a la entrada de la LSTM. La CNN produce una salida del tipo (width, height, filters) pero la LSTM requiere un vector de entrada en una dimensión. La capa Flatten no aprende nada ni ajusta pesos, sólo cambia la forma de los vectores.

```

1
2
3     # CNN-LSTM MODEL (Keras 3 Compliant)
4     myCNNLSTM = Sequential()
5     myCNNLSTM.add(Input(batch_shape=(batch_size, look_back, 7, 7,
6     1)))
7     myCNNLSTM.add(TimeDistributed(Conv2D(filters=current_filters,
8     kernel_size=(3,3), padding='same', activation='relu'))))
9     myCNNLSTM.add(TimeDistributed(Flatten())) # Flatten to connect
10    CNN to LSTM
11    myCNNLSTM.add(LSTM(look_back, stateful=True))
12    myCNNLSTM.add(Dense(num_features))
13    myCNNLSTM.compile(loss='mean_squared_error', optimizer='adam')

```

Listing 9: Añadido enable_op_determinism()

He descartado con unas simulaciones iniciales y con un poco de lógica aumentar el número de capas. La red es perfectamente capaz de seguir

2.4.1 Resultados

Tras ejecutar varias veces el script de Grid Search no parece que haya una mejoría notable en los resultados de la red neuronal CNNLSTM frente a sólo LSTM. Además, el tiempo de procesamiento aumenta bastante y por si no fuera poco, los resultados no son reproducibles.

Como en la red 7x7LSTM, he intentado ir afinando los hiperparámetros: una ventana de 24 horas, batches de 25 ventanas, threshold del 5%, n_epoch_updates entre 5 y 7 y entre 16 y 20 filtros para la capa convolucional.

3 Reproducibilidad 28/04/2026

He conseguido hacer que los entrenamientos con Kaggle sean reproducibles. Tendré que volver a realizar los entrenamientos. Eso me supondrá crear una nueva cuenta de Kaggle para tener otras 30 horas gratis.

```
1 # fix random seed for reproducibility
2 os.environ['PYTHONHASHSEED'] = '0'
3 os.environ['TF_DETERMINISTIC_OPS'] = '1'
4 os.environ['TF_CUDNN_DETERMINISTIC'] = '1'
5 os.environ['TF_ENABLE_ONEDNN_OPTS'] = '0'
6 random.seed(7)
7 np.random.seed(7)
8 tf.random.set_seed(7)
9 tf.config.experimental.enable_op_determinism()
```

Listing 10: Añadido enable_op_determinism()

Estas medidas hacen que el entrenamiento sea extremadamente lento puesto que estoy forzado a las CPU y GPUs a ser completamente deterministas, sin que puedan aumentar su eficiencia usando procesamiento en paralelo.

Voy a necesitar varias cuentas de Kaggle pero eso no es un problema.

3.1 Resultados LSTM

He utilizado un Grid Search con pocos valores puesto que era una prueba de reproducibilidad y suponía que la velocidad de procesamiento se vería afectada (alrededor de 8 horas de procesamiento).

He probado los siguientes valores:

```
1 #Parameter tweak
2 hyperparameters = {
3     'look_back': [16, 18],
4     'batch_size': [22, 23, 24],
5     'n_epochs_update': [6, 7],
6     'threshold': [0.13, 0.15],
7 }
```

Listing 11: Grid Search LSTM reproducible

Dichos valores están sacados de las pruebas que realicé cuando el código no era reproducible. Ahora que sé que es reproducible, volveré a probar otros valores para tener las medidas correctas.

Los 3 mejores resultados han sido con `lookback=18h`, `batches_size=[23,24]`, `n_epoch_update=[6,7]` y `threshold=0.13`.

En las combinaciones ganadoras el test estático ha tenido un 10% más de RNMSE que el entrenamiento incremental, estando el test estático alrededor de 0.31 y el entrenamiento incremental alrededor de 0.23. Sin embargo, el entrenamiento incremental tiene una varianza mayor a lo largo de las diferentes combinaciones, variando entre 0.21 y 0.518, mientras el test estático se mantiene prácticamente constante independientemente de los hiperparámetros.

3.2 Resultados CNN+LSTM

También he utilizado un Grid Search con pocos valores sacados de las simulaciones no reproducibles puesto que era una prueba de reproducibilidad y suponía que la velocidad de procesamiento se vería afectada (alrededor de 10 horas de procesado).

He probado los siguientes valores:

```
1 #Parameter tweak
2 hyperparameters = {
3     'look_back': [12, 24],
4     'batch_size': [20, 25],
5     'n_epochs_update': [6, 7],
6     'threshold': [0, 0.1],
7     'num_filters': [16, 20]
8 }
```

Listing 12: Grid Search CNN+LSTM reproducible

Los resultados son reproducibles pero no muy esperanzadores. Los 3 mejores resultados fueron con `lookback=24h`, `batch_size=25`, `n_epochs_update=[6,7]`, `threshold=[0,0.1]` y entre 16 y 20 filtros.

Los resultados no han supuesto una mejora respecto a la red neuronal LSTM. El valor del RNMSE de CNN+LSTM en cuanto a entrenamiento incremental es muy parecido sin llegar a superar el de LSTM.

Cabe destacar que con la red CNN el RNMSE del entrenamiento incremental es más estable entre combinaciones de hiperparámetros que con sólo la red LSTM.

4 Acciones futuras

Como el Grid Search de ambas redes neuronales todavía puede arrojar valores mejores de RNMSE, probaré otros hiperparámetros. También probaré a aumentar el número de capas de las redes neuronales para ver si hay alguna mejora aunque sin muchas esperanzas.